# HW3_Aceves_Daniel

September 22, 2026

8.2

TAREA 3: análisis de relaciones entre variables del OOIP

Aceves Maya Christopher Daniel

Temas selectos

fecha de entrega 17 de septiembre de 2026

DR. MOISES VELASCO LOZANO

1. Introducción

El objetivo de la tarea es aplicar los métodos de covarianza por pares, coeficiente de correlación por pares y coeficiente de correlación por rangos a los datos contenidos en el archivo OOIP.csv, con el propósito de identificar y ordenar las propiedades del yacimiento de acuerdo con su grado de asociación con el volumen original de aceite, N (MMSTB).

2. Desarrollo

Como primera parte del desarrollo vamos a importar las librerías, cargamos los datos y definimos variables; área, espesor, porosidad, saturación de aceite SO, y el factor volumétrico del aceite BO

[1]:
```
import numpy as np, pandas as pd, matplotlib.pyplot as plt
from scipy import stats
%matplotlib inline

# Cargar datos
url = "https://raw.githubusercontent.com/Moises13r/PetroleumEng/main/
 ↪Special%20Topics/Data/OOIP.csv"
df = pd.read_csv(url)
print(df.head())

# Definir variables
Y = df['N (MMSTB)'].values
X = {
    'Area': df['Area (acres)'].values,
    'Thickness': df['Thickness h (ft)'].values,
    'Porosity': df['Porosity'].values,
    'So': df['Oil Saturation So'].values,
    'Bo': df['Oil FVF Bo (rb/STB)'].values}
```

10

```
   Sample  Area (acres)  Thickness h (ft)  Porosity  Oil Saturation So  \
0       1        1051.9              10.8     0.141              0.539
```

```
1       2        1108.6              107.9     0.099              0.619
2       3         412.3               64.6     0.086              0.530
3       4         908.3               32.7     0.210              0.774
4       5        1304.8               86.2     0.155              0.512

   Oil FVF Bo (rb/STB)  N (MMSTB)  Grouped Feature
0                1.418      4.724           608.88
1                1.065     53.398          6882.92
2                1.375      6.850           882.91
3                1.053     35.568          4584.68
4                1.529     45.289          5837.75
```

2.1 desarrollo

Para la siguiente parte vamos a realizar los cálculos con el método de la covarianza por pares, correlación por pares y correlación por rangos

[2]:
```
# COVARIANZA POR PARES
cov = {k: np.cov(v, Y, ddof=1)[0,1] for k, v in X.items()}
df_cov = pd.DataFrame({'Propiedad': list(cov.keys()), 'Covarianza': list(cov.
 ↪values())})
df_cov = df_cov.sort_values('Covarianza', ascending=False).
 ↪reset_index(drop=True)
print("\n COVARIANZA POR PARES CON N:")
print(df_cov.to_string(index=False))

plt.figure(figsize=(10,5))
plt.bar(df_cov['Propiedad'], df_cov['Covarianza'], color='steelblue',␣
 ↪edgecolor='black')
plt.title('Covarianza por Pares con N (MMSTB)'); plt.xlabel('Propiedad'); plt.
 ↪ylabel('Covarianza')
plt.xticks(rotation=45, ha='right'); plt.grid(True, alpha=0.3); plt.
 ↪tight_layout(); plt.show()

# CORRELACIÓN POR PARES
pares = {k: stats.pearsonr(v, Y)[0] for k, v in X.items()}
df_p = pd.DataFrame({'Propiedad': list(pares.keys()), 'Correlación por pares':␣
 ↪list(pares.values())})
df_p = df_p.sort_values('Correlación por pares', ascending=False).
 ↪reset_index(drop=True)
print("\n CORRELACIÓN POR PARES CON N:")
print(df_p.to_string(index=False))

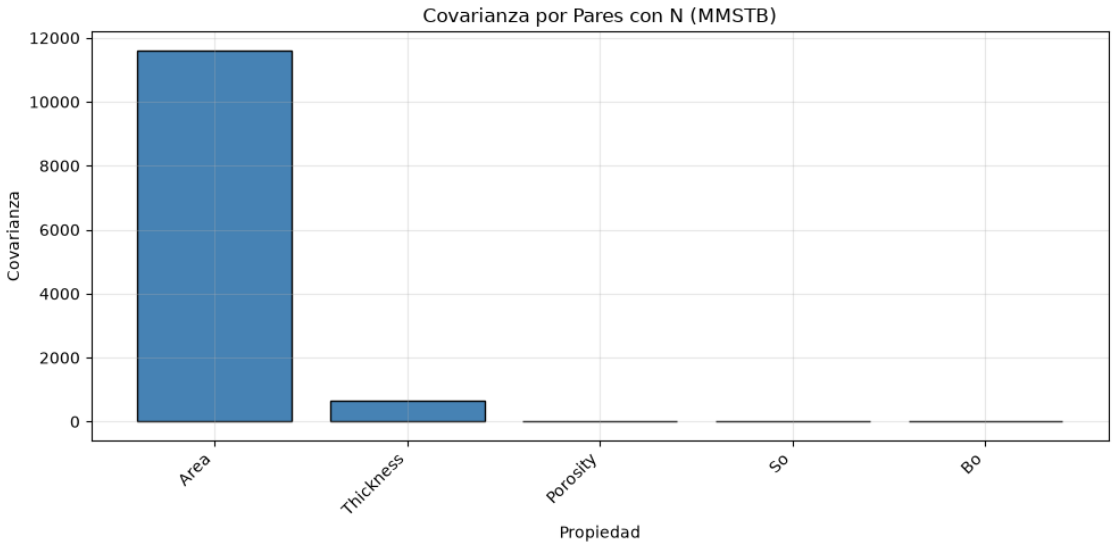
plt.figure(figsize=(10,5))
plt.bar(df_p['Propiedad'], df_p['Correlación por pares'], color='coral',␣
 ↪edgecolor='black')
plt.title('Correlación por Pares con N'); plt.xlabel('Propiedad'); plt.
 ↪ylabel('Coeficiente')
```

```
plt.xticks(rotation=45, ha='right'); plt.axhline(0, color='black', lw=0.5)
plt.grid(True, alpha=0.3); plt.tight_layout(); plt.show()

# CORRELACIÓN POR RANGOS
rangos = {k: stats.spearmanr(v, Y)[0] for k, v in X.items()}
df_s = pd.DataFrame({'Propiedad': list(rangos.keys()), 'Correlación por rangos':
 ↪ list(rangos.values())})
df_s = df_s.sort_values('Correlación por rangos', ascending=False).
 ↪reset_index(drop=True)
print("\n CORRELACIÓN POR RANGOS CON N:")
print(df_s.to_string(index=False))

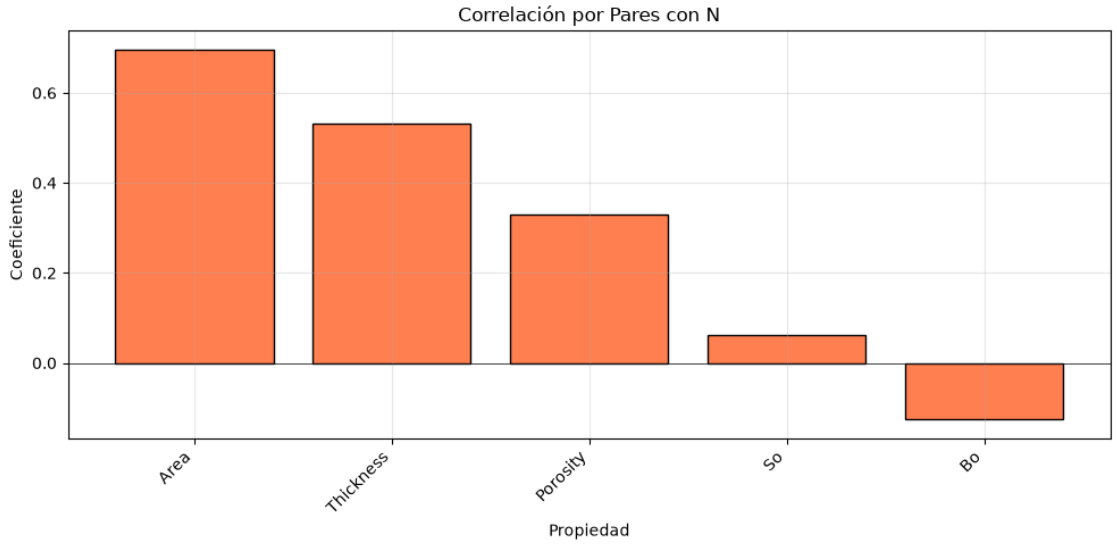
plt.figure(figsize=(10,5))
plt.bar(df_s['Propiedad'], df_s['Correlación por rangos'], color='lightgreen',␣
 ↪edgecolor='black')
plt.title('Correlación por Rangos con N'); plt.xlabel('Propiedad'); plt.
 ↪ylabel('Coeficiente')
plt.xticks(rotation=45, ha='right'); plt.axhline(0, color='black', lw=0.5)
plt.grid(True, alpha=0.3); plt.tight_layout(); plt.show()
```

```
 COVARIANZA POR PARES CON N:
Propiedad   Covarianza
     Area 11614.215599
Thickness   661.837836
 Porosity     0.691458
       So     0.273025
       Bo    -0.728360
```



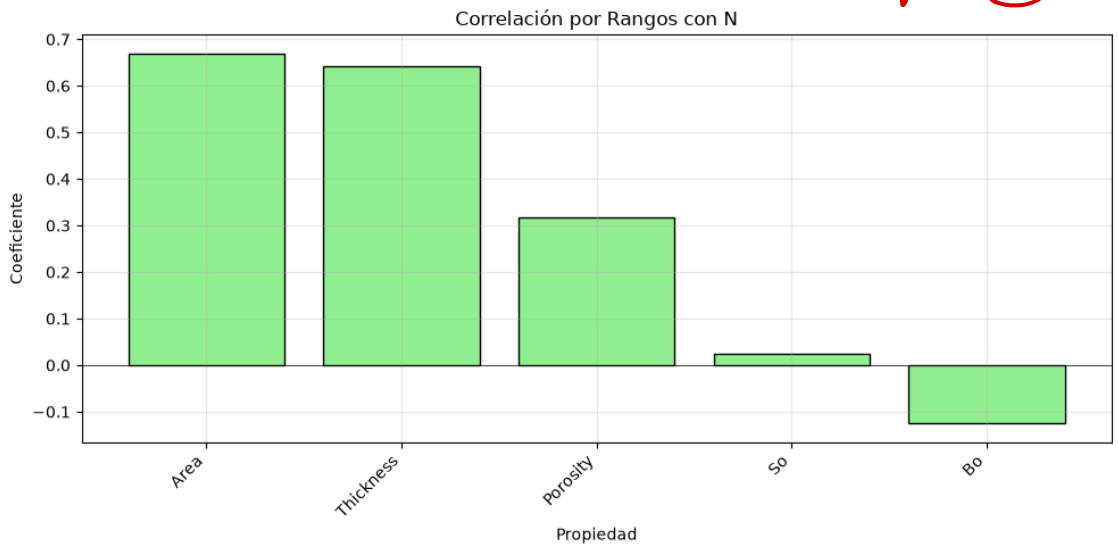
CORRELACIÓN POR PARES CON N:

| Propiedad | Correlación por pares |
|---|---|
| Area | 0.696850 |
| Thickness | 0.531701 |
| Porosity | 0.330148 |
| So | 0.061324 |
| Bo | -0.125944 |




CORRELACIÓN POR RANGOS CON N:

| Propiedad | Correlación por rangos |
|---|---|
| Area | 0.669916 |
| Thickness | 0.643024 |
| Porosity | 0.317453 |
| So | 0.024017 |
| Bo | -0.125672 |




2.2 desarrollo

Para la última parte vamos a realizar una tabla y una gráfica comparativa de los 3 métodos utilizados

[3]:
```
# TABLA COMPARATIVA
tabla = pd.DataFrame({
    'Propiedad': list(X.keys()),
    'Covarianza': [cov[k] for k in X],
    'Correlación por pares': [pares[k] for k in X],
    'Correlación por rangos': [rangos[k] for k in X]
})
tabla['Rank_Cov'] = tabla['Covarianza'].rank(ascending=False).astype(int)
tabla['Rank_Pares'] = tabla['Correlación por pares'].rank(ascending=False).
 ↪astype(int)
tabla['Rank_Rangos'] = tabla['Correlación por rangos'].rank(ascending=False).
 ↪astype(int)
tabla['Rank_Prom'] = ((tabla['Rank_Cov'] + tabla['Rank_Pares'] +␣
 ↪tabla['Rank_Rangos'])/3).round(2)
tabla = tabla.sort_values('Rank_Prom').reset_index(drop=True)
tabla.index += 1

print("TABLA COMPARATIVA:")
print(tabla.round(4).to_string())

# GRÁFICA COMPARATIVA
fig, ax = plt.subplots(figsize=(12,6))
x = np.arange(len(X)); w = 0.25
ax.bar(x-w, tabla['Covarianza']/tabla['Covarianza'].max(), w, label='Covarianza␣
 ↪(norm)', color='steelblue', edgecolor='black')
```

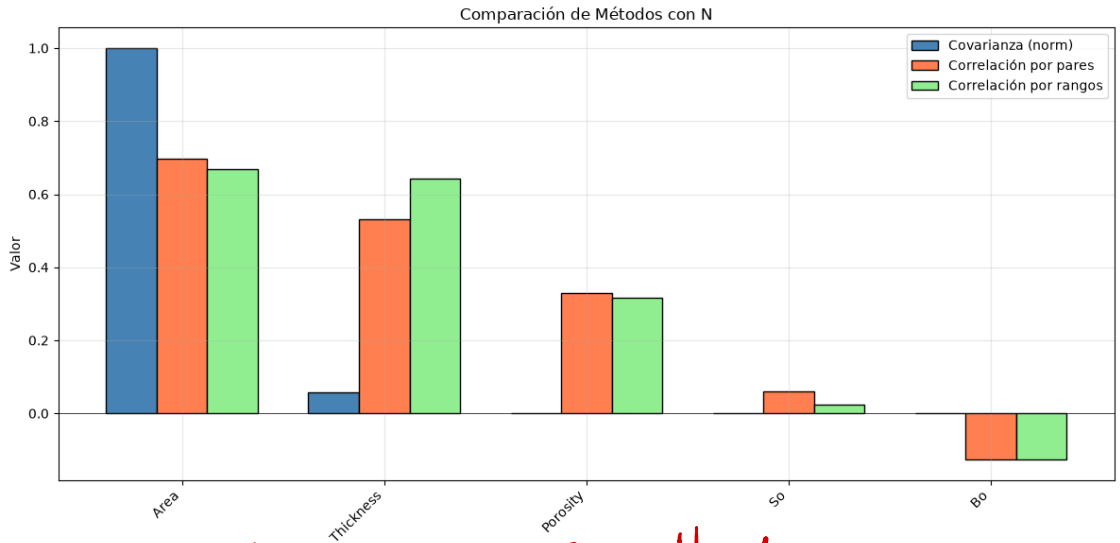
```
ax.bar(x, tabla['Correlación por pares'], w, label='Correlación por pares',␣
 ↪color='coral', edgecolor='black')
ax.bar(x+w, tabla['Correlación por rangos'], w, label='Correlación por rangos',␣
 ↪color='lightgreen', edgecolor='black')
ax.set_xticks(x); ax.set_xticklabels(tabla['Propiedad'], rotation=45,␣
 ↪ha='right')
ax.set_title('Comparación de Métodos con N'); ax.set_ylabel('Valor')
ax.axhline(0, color='black', lw=0.5); ax.legend(); ax.grid(True, alpha=0.3)
plt.tight_layout(); plt.show()

print(f"\n La propiedad con mayor asociación con N es: {tabla.
 ↪iloc[0]['Propiedad']}")
```

10

Mejora en la Presentación de la tabla comparativa ✓

```
TABLA COMPARATIVA:
   Propiedad  Covarianza  Correlación por pares  Correlación por rangos
Rank_Cov  Rank_Pares  Rank_Rangos  Rank_Prom
1       Area  11614.2156                0.6968                 0.6699
1          1           1       1.0
2  Thickness    661.8378                0.5317                 0.6430
2          2           2       2.0
3   Porosity      0.6915                0.3301                 0.3175
3          3           3       3.0
4         So      0.2730                0.0613                 0.0240
4          4           4       4.0
5         Bo     -0.7284               -0.1259                -0.1257
5          5           5       5.0
```




✓

Interpretación de Resultados

```
La propiedad con mayor asociación con N es: Area
```

✓ 10

3.0 conclusión

El objetivo de identificar y ordenar las propiedades del yacimiento de acuerdo con su grado de asociación con el volumen original de aceite nos da como resultado después del análisis comparativo de los métodos utilizados que la variable con mayor asociación al volúmen original de aceite es el área en este caso en particular, seguido del espesor de la roca.

4.0 referencias

MoisesVL. (s/fb). Special topics/notes at main · Moises13r/PetroleumEng.

MoisesVL. (s/f-a). Special topics/data/OOIP.Csv at main · Moises13r/PetroleumEng.

